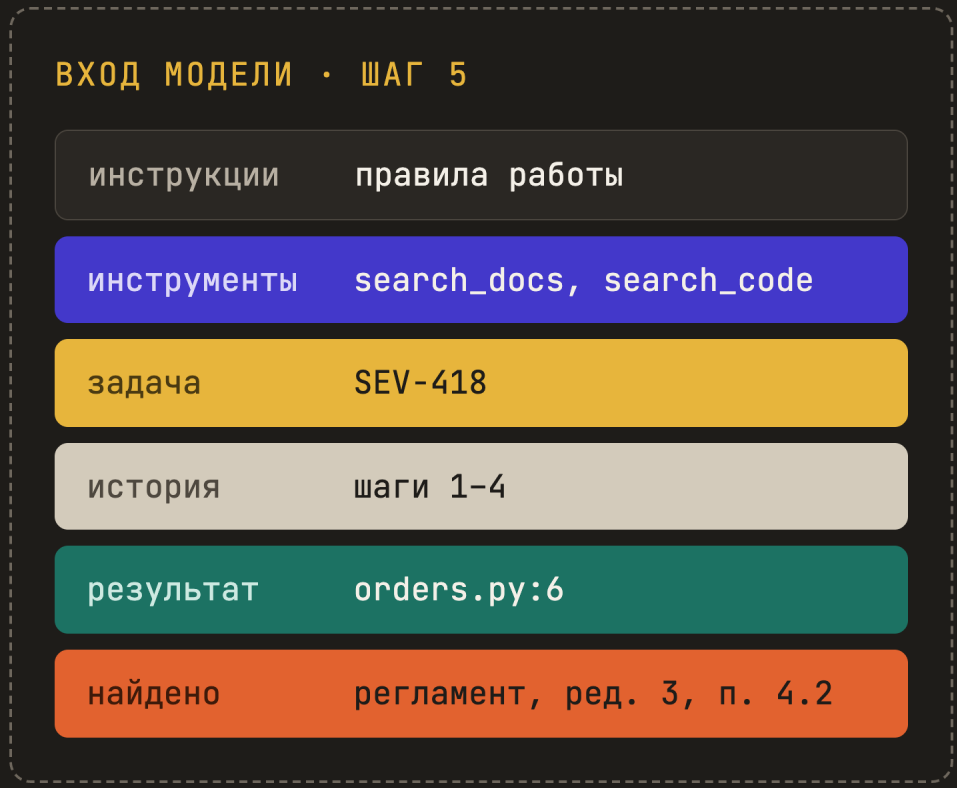
LLM И AI-АГЕНТЫ · ЗАНЯТИЕ 3

Контекст агента и RAG

Как сформировать контекст, найти нужные сведения и использовать их при решении задачи



github.com/Vasiliy566/hsm_lectures · wave_2/lesson_03

Где мы остановились

ЗАНЯТИЕ 2

Мини-кодер

`list_files` `read_file`

`write_file` `run_tests`

весь проект во входе

ДЗ 2

Агент для репозитория

`search_code`

`read_file по строкам`

`replace_in_file`

сам находит нужный код

СЕГОДНЯ

Сведения вне кода

`регламенты` `вики` `тикеты`

контекст растёт с каждым шагом

План занятия

1

Контекст агента

2

Поиск: RAG

3

Отбор и проверка

01

Контекст агента

Что модель видит на каждом шаге и кто это решает

Контекст — всё, что во входе

ВХОД МОДЕЛИ · ШАГ 5

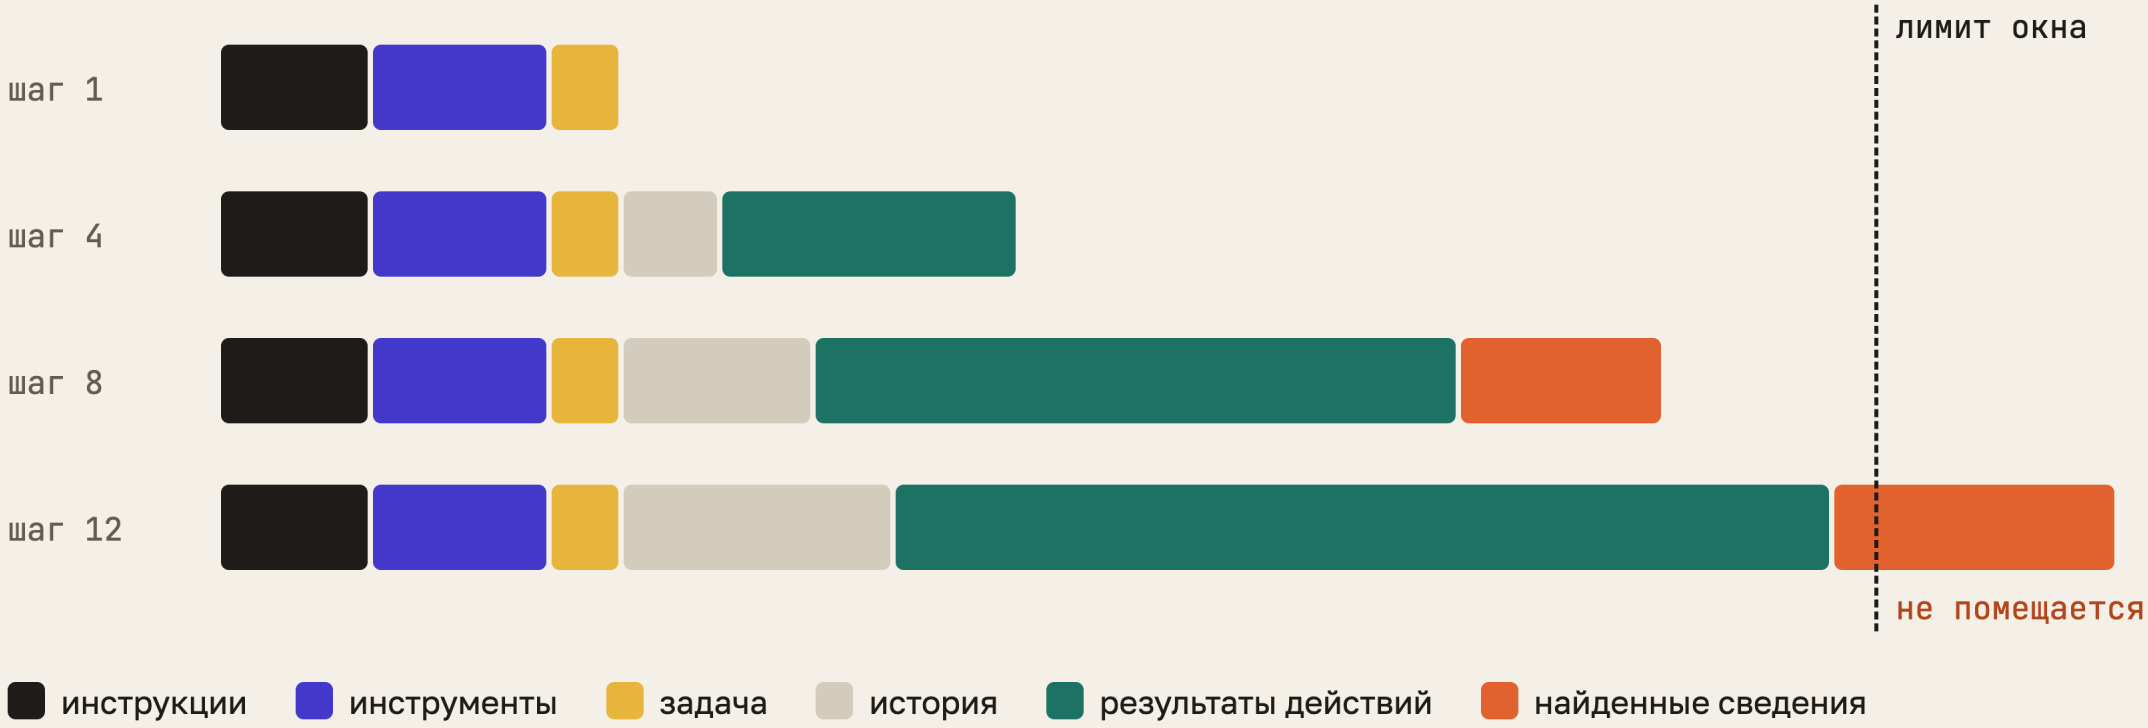
Инструкции	правила работы, формат отчёта
Инструменты и skills	описания search_code, read_file
Задача	SEV-418: адрес и экспресс-доставка
История	сообщения и вызовы шагов 1–4
Результаты действий	вывод search_code, run_tests
Найденные сведения	регламент, ред. 3, п. 4.2
Состояние работы	план, что сделано, заметки

ВНЕ ВХОДА

- остальные файлы репозитория
- другие разделы регламента
- тикеты за прошлый год
- договорённости в головах команды

Для модели этого нет

Контекст меняется на каждом шаге



Почему не передать всё сразу



Окно

всё сразу не помещается



Цена и время

каждый токен — на каждом шаге



Шум

context rot



Доступ

права и редакции

КОНТЕКСТ-ИНЖИНИРИНГ

Выбрать минимальный набор сведений, достаточный для решения задачи на этом шаге

«...the smallest possible set of high-signal tokens that maximize the likelihood of some desired outcome»

Anthropic · Effective context engineering for AI agents

02

Поиск: RAG

Как найти нужное в большой базе и передать модели

Модель, чат-продукт и ваша система

Модель

знания до даты обучения

регламент **нет**

Чат-продукт

+ поиск в интернете

регламент **нет**

Ваша система

+ ваши регламенты и код

регламент **есть**

Новая задача: сведения вне кода

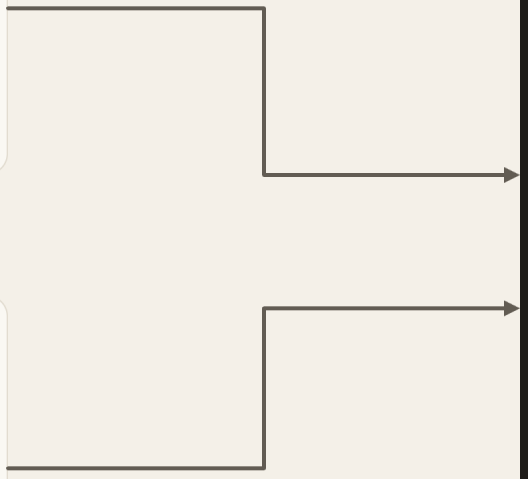
ЗАДАЧА ДЛЯ МИНИ-КОДЕРА

SEV-418

Смена адреса работает не по регламенту для экспресс-заказов

ВОПРОС В ПОДДЕРЖКУ

Заказ уже оплачен. Можно поменять адрес?



ИСТОЧНИК · ВНУТРЕННИЙ

Регламент изменения заказа

ред. 3 · действует с 01.10.2026

п. 4.2 Изменение адреса доставки

+ исключение для экспресс-доставки

ДЕМО 1

Без документа и с документом

github.com/Vasiliy566/hsm_lectures
wave_2/lesson_03/practice

ЗАПУСКАЕМ

```
python 01_without_and_with_docs.py
```

А без регламента

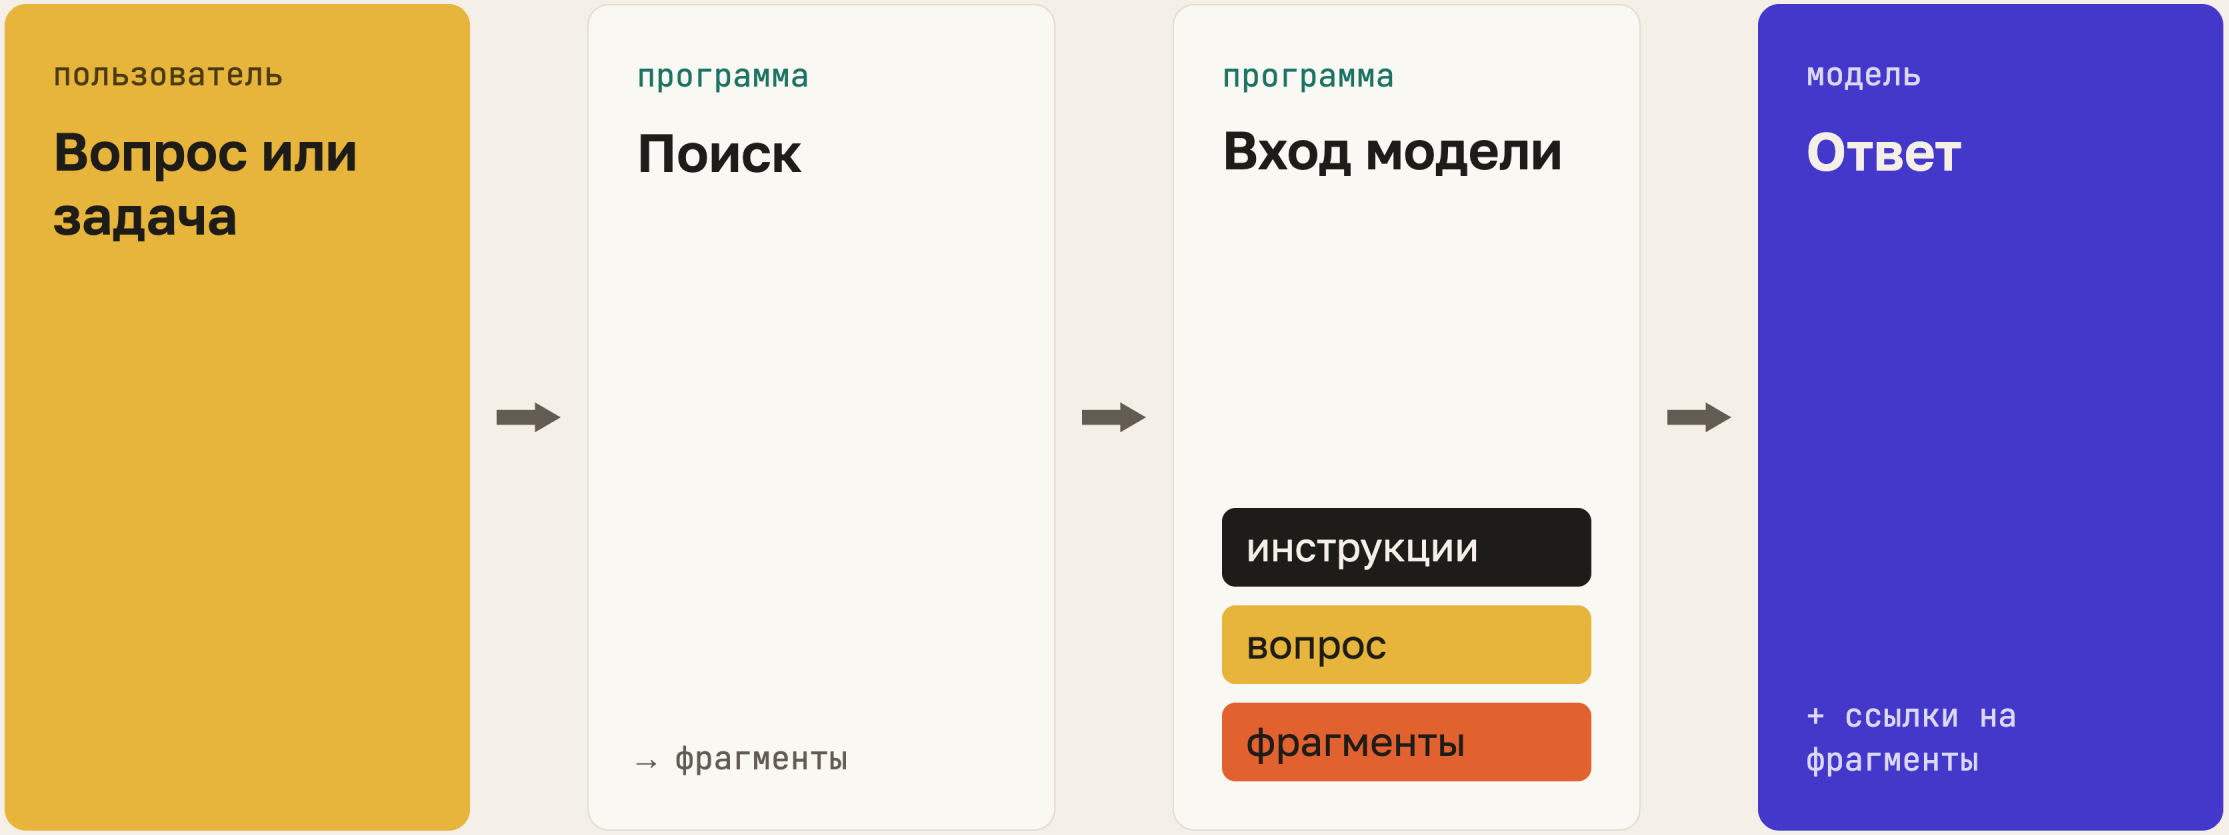
Б регламент ред. 3 целиком во входе

СМОТРИМ

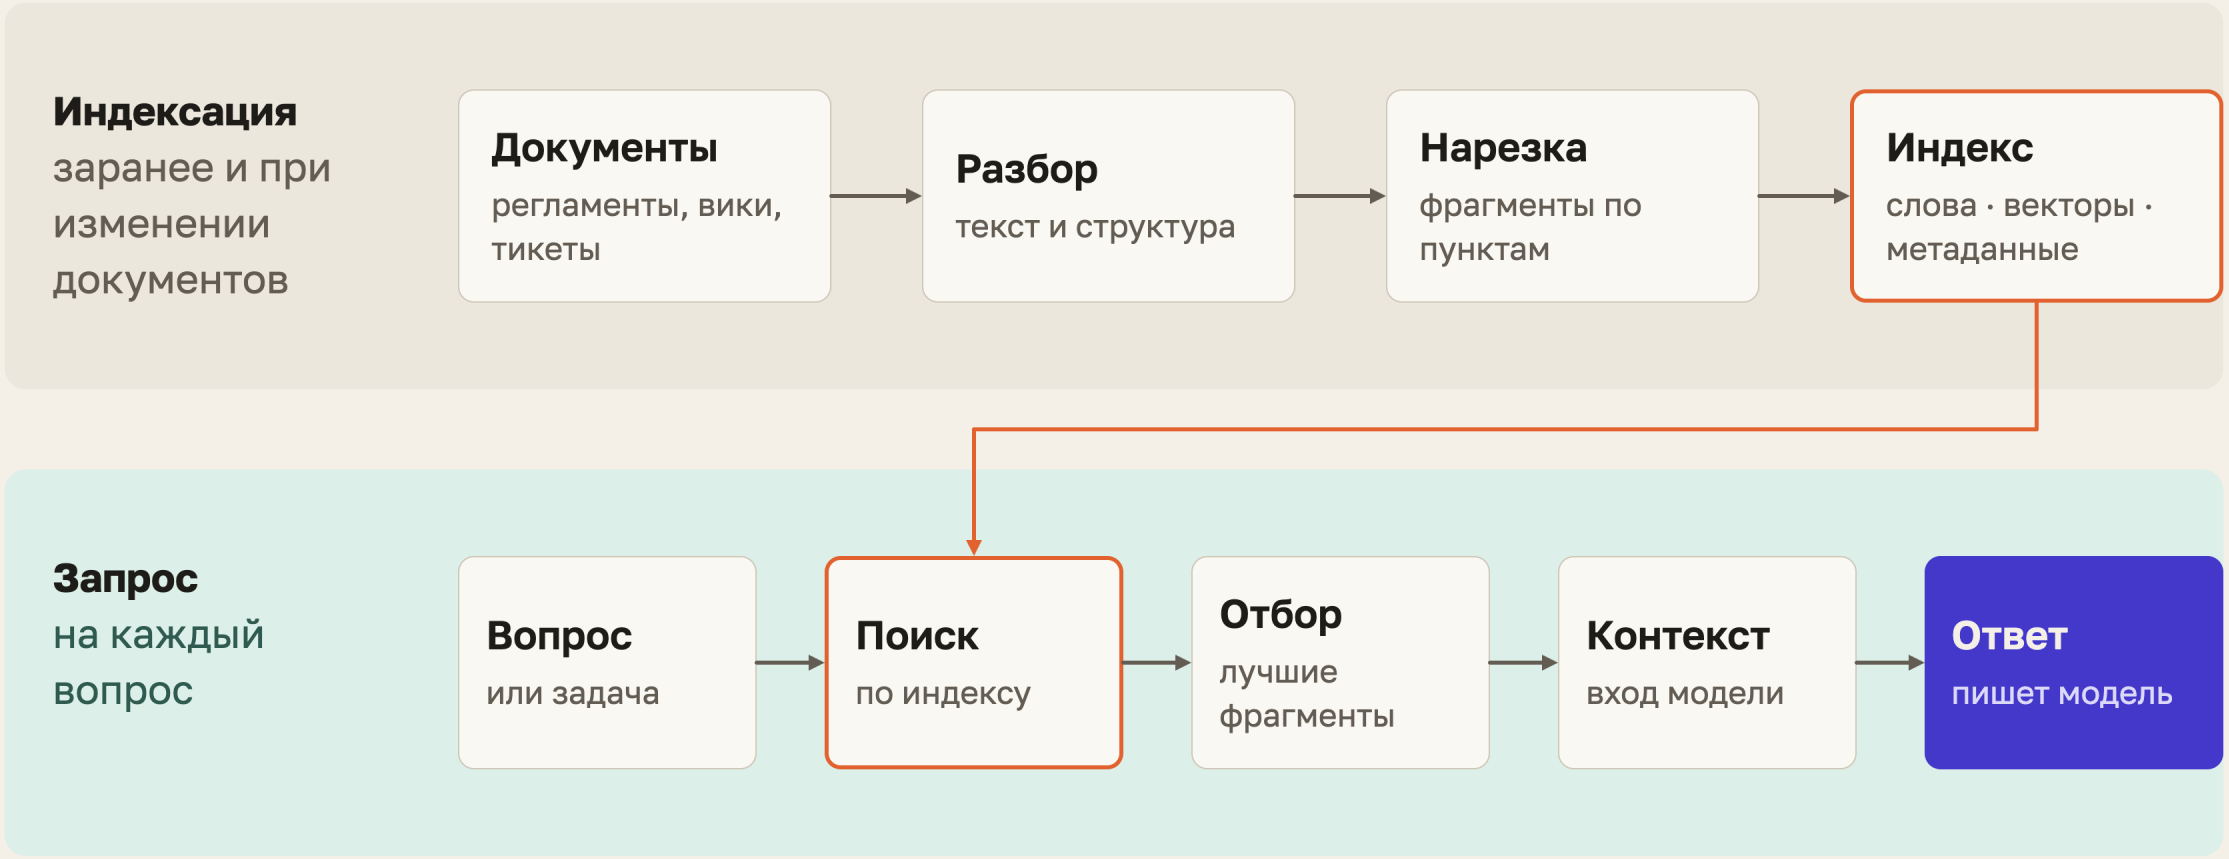
- На что опирается ответ
- Учтено ли исключение для экспресс-доставки
- Сколько токенов во входе

RAG: найти и добавить во вход

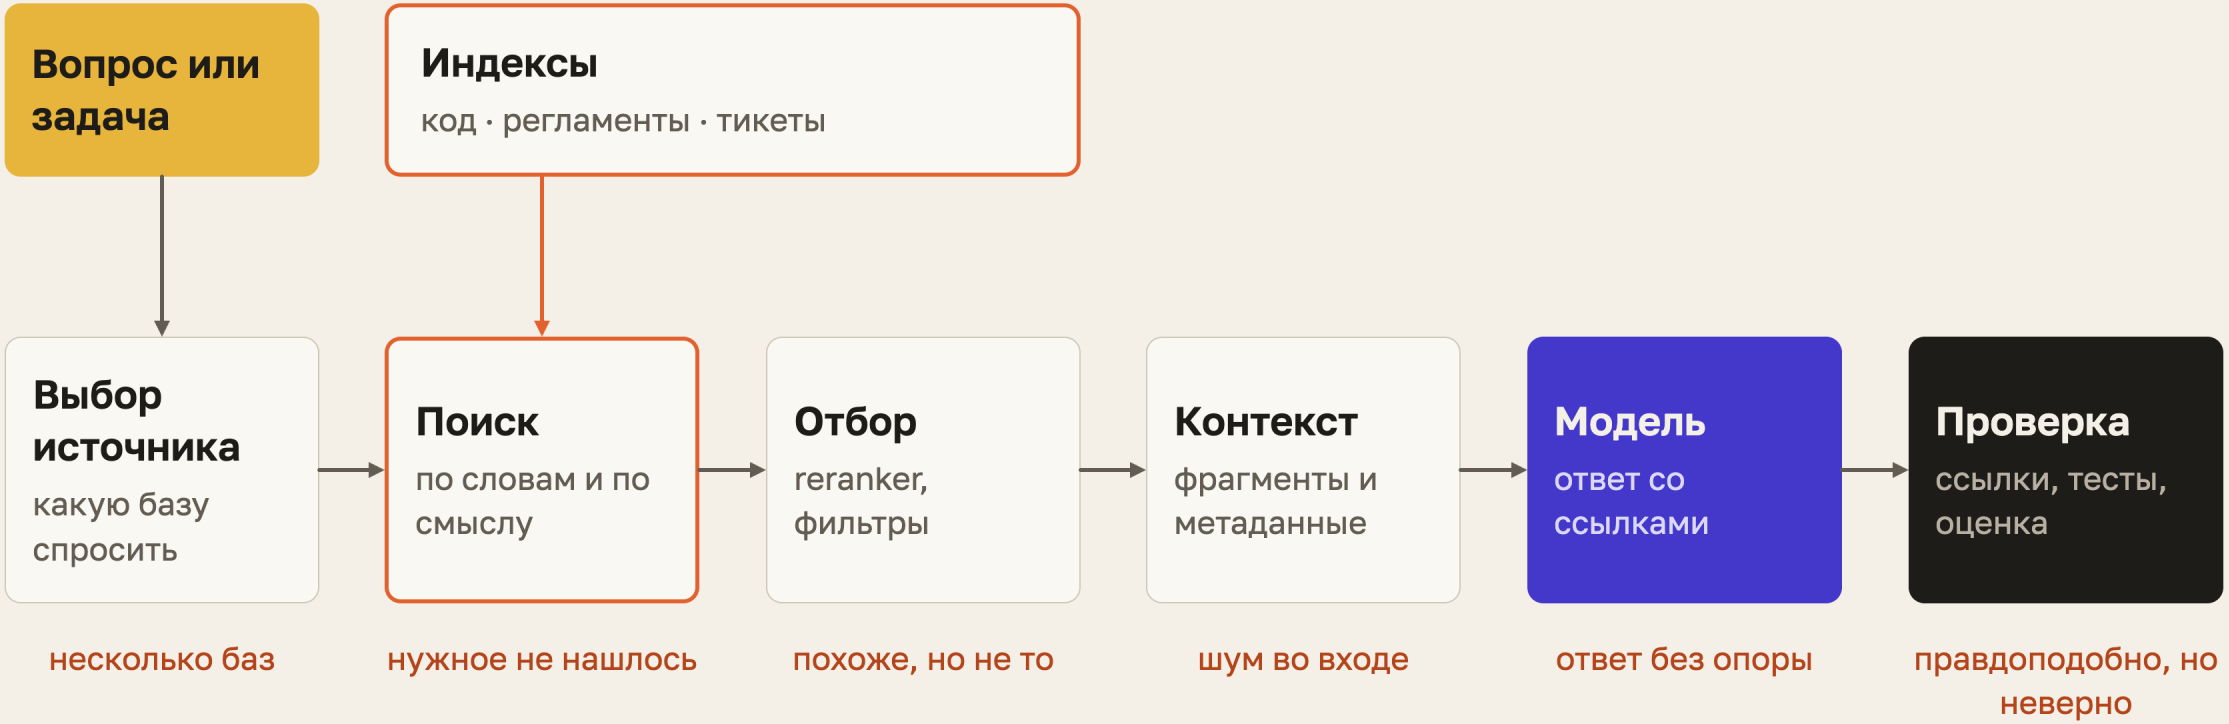
RETRIEVAL-AUGMENTED GENERATION



Два этапа: индексация и запрос



Общая схема


Вопрос или задача
Индексы
код · регламенты · тикеты
Выбор источника
какую базу спросить
Поиск
по словам и по смыслу
Отбор
reranker, фильтры
Контекст
фрагменты и метаданные
Модель
ответ со ссылками
Проверка
ссылки, тесты, оценка
несколько баз
нужное не нашлось
похоже, но не то
шум во входе
ответ без опоры
правдоподобно, но неверно

RAG — подход, а не хранилище

ПОДХОД

RAG

найти сведения → добавить во вход → ответить с опорой на них

СПОСОБ ПОИСКА

Как ищем

- по словам · BM25
- по смыслу · эмбеддинги
- гибрид
- grep по коду
- внешний сервис

ХРАНИЛИЩЕ

Где лежит

- файлы
- PostgreSQL + pgvector
- Elasticsearch, OpenSearch
- векторная БД

Поиск по словам

ВОПРОС

Можно поменять адрес, если заказ уже собирают?

в вопросе	в регламенте	совпало?
адрес	адрес	да
заказ	заказа	после нормализации
поменять	изменить	нет: синоним
собирают	сборка	нет: другое слово

НАХОДИТ

`picking` `SEV-418` `A127` `can_change_address`

ВЫДАЧА · TOP-3

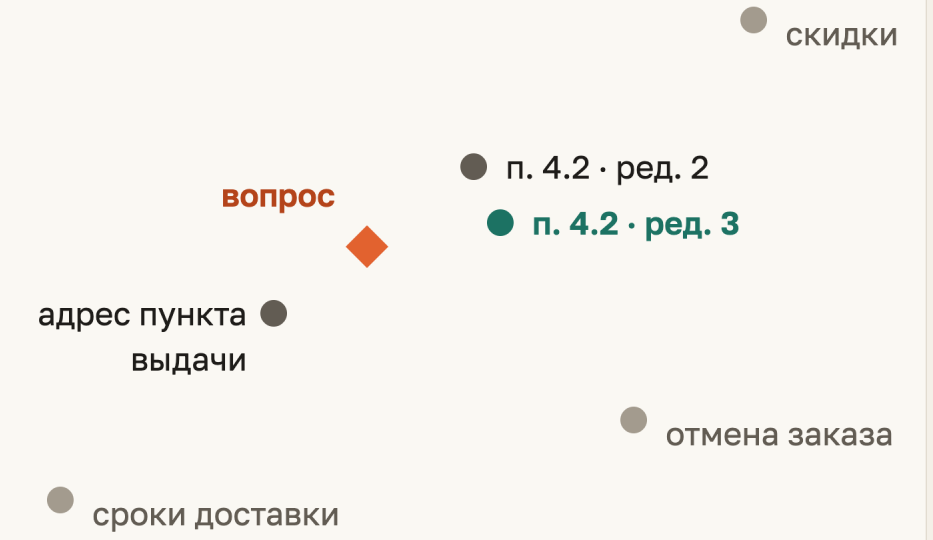
1 · адрес пункта выдачи

2 · п. 4.2, ред. 2

3 · п. 4.2, ред. 3

Поиск по смыслу

ТЕКСТ → ВЕКТОР · БЛИЗКИЙ СМЫСЛ → БЛИЗКИЕ ВЕКТОРЫ



НАХОДИТ

«поменять» ≈ «изменить»

ОШИБАЕТСЯ

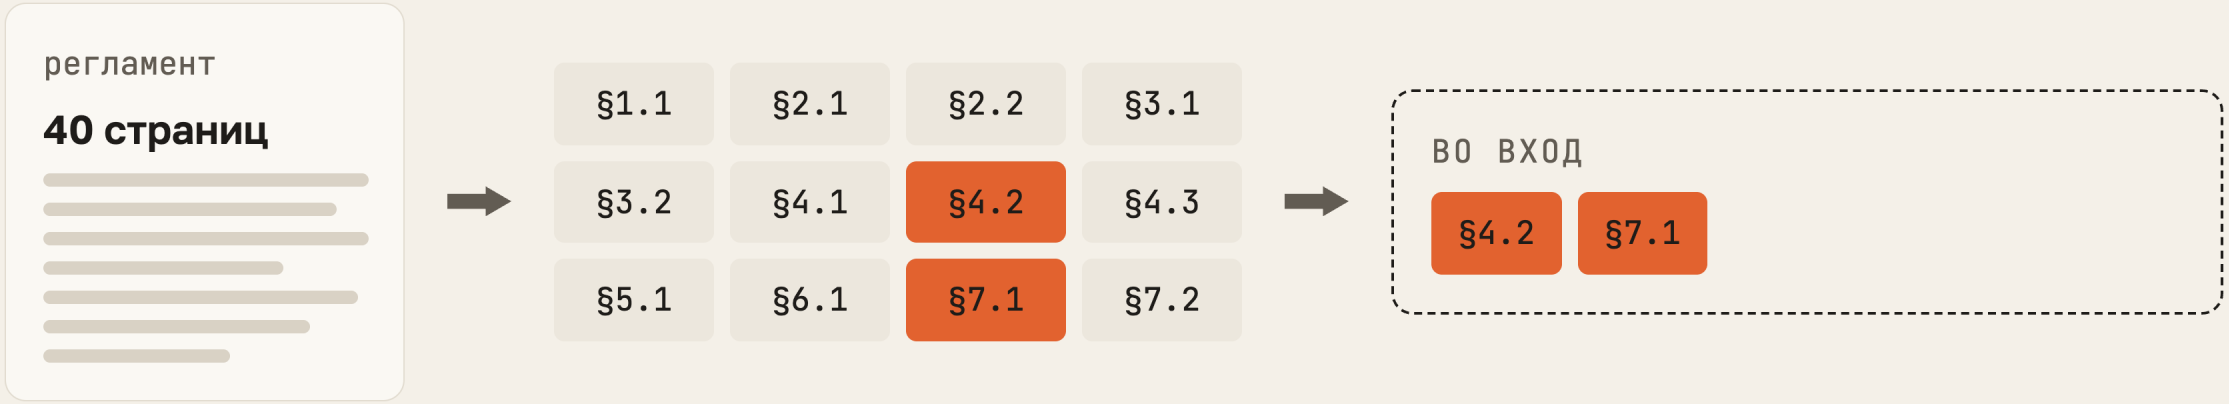
похожая тема ≠ ответ

редакции 2 и 3 почти неразличимы

Гибридный поиск и reranker



Зачем делить документы



задача 1

Найтись

короткий, про одно

задача 2

Сохранить смысл

понятен без соседей

задача 3

Хватить для ответа

условие + исключение

Условие потерялось на границе

policy-v3#3 · найден

...4.2. Изменение адреса доставки Клиент может изменить адрес доставки, пока не началась сборка заказа: статусы new и paid. После начала сборки адрес изменить нельзя: заказ уже комплектуется на складе по исходному маршруту.

---------- граница: 400 символов ----------

policy-v3#4 · не найден

Исключение: для заказов с экспресс-доставкой это действие доступно только до оплаты, в статусе new. Если клиент настаивает, оператор предлагает отменить заказ и оформить новый. 4.3. Отмена заказа Клиент может отменить...

вопрос

Заказ уже оплачен. Можно поменять адрес?

из найденного следует

Да: в статусе paid адрес изменить можно.

⚠ **Неверно для экспресс-доставки**

Три способа исправить нарезку

способ 1

По структуре

по пунктам, а не по символам

4.1 Изменение состава

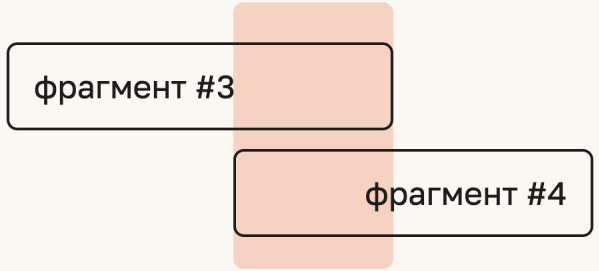
4.2 Изменение адреса

4.3 Отмена заказа

способ 2

С перекрытием

соседи делят пару предложений



способ 3

С контекстом

документ, редакция, раздел

```
[Регламент изменения заказа,
ред. 3, действует 2026-10-01
— сейчас]
4.2. Изменение
адреса доставки
…Исключение: для заказов с
экспресс-доставкой…
```

Проверяем, что исправление помогло

изменение

Нарезка по пунктам вместо 400 символов

→

поиск

Исключение в top-5: 2 → 10 из 10

→

ответ

Учтена экспресс-доставка?

Нужный фрагмент в top-5	По размеру	По пунктам	+ заголовок
Вопросы про исключение	2 / 10	10 / 10	10 / 10
Обычные вопросы	10 / 10	10 / 10	10 / 10

Замер Anthropic

НУЖНЫЙ ФРАГМЕНТ НЕ ПОПАЛ В TOP-20 · ИСХОДНО 5,7%

−35%

5,7% → 3,7%

Пояснения к фрагментам, поиск по смыслу

−49%

5,7% → 2,9%

+ поиск по словам по тем же фрагментам

−67%

5,7% → 1,9%

+ reranker

Anthropic · Contextual Retrieval, 2024

ДЕМО 2

Поиск и нарезка

ЗАПУСКАЕМ

```
python 02_three_searches.py
```

один вопрос: по словам, по смыслу, гибрид

```
python 03_chunking.py
```

нарезка по размеру и по пунктам

СМОТРИМ

- Какие фрагменты в top-5 и почему
- Где оказался фрагмент с исключением
- Что отвечает модель по найденному

github.com/Vasiliy566/hsm_lectures
wave_2/lesson_03/practice

Формулировка вопроса и история

ДИАЛОГ

У меня заказ A311 с экспресс-доставкой

Вижу заказ A311, статус paid

А адрес ещё можно поменять?



ЗАПРОС = ПОСЛЕДНЕЕ СООБЩЕНИЕ

а адрес ещё можно поменять

⚠ Экспресс-доставка потерялась

ЗАПРОС ПОСЛЕ ПЕРЕФОРМУЛИРОВКИ

изменение адреса доставки, экспресс-доставка, статус paid

✓ Находит п. 4.2 вместе с исключением

Поиск по коду

```
› search_code("can_change_address")
shop/orders.py:6: def can_change_address(status: str) → bool:
shop/orders.py:15: verdict = "можно" if can_change_address…
tests/test_orders.py:3: from shop.orders import can_change…
+ ещё 6 совпадений в tests/test_orders.py

› read_file("shop/orders.py", 1, 16)
16 строк с номерами

› search_code("express")
shop/delivery.py:6: def estimate_days(city: str, express…
+ ещё 3 совпадения
```

Имена точные

поиск по словам + чтение по строкам

Claude Code

CLAUDE.md сразу, файлы — glob и grep

Индекс по смыслу

«где считается скидка?»

03

Отбор и проверка

Что из найденного применимо и как это проверить

Похоже ≠ применимо

ред. 2 до 30.09.2026

Клиент может изменить адрес доставки, пока не началась сборка заказа: статусы new и paid.

score по словам: 4,01

ред. 3 с 01.10.2026

Клиент может изменить адрес доставки, пока не началась сборка заказа: статусы new и paid. Исключение: для заказов с экспресс-доставкой это действие доступно только до оплаты.

score по словам: 3,76

Заказ A311 от 28.09.2026 → действует ред. 2

правило магазина: редакция на дату оформления

метаданные: `doc_id` `version` `valid_from` `valid_to` `access`

Высокий score ≠ готовый ответ

SCORE ИЗМЕРЯЕТ

Насколько текст фрагмента похож на запрос



SCORE НЕ ЗНАЕТ

1. Есть ли во фрагменте ответ
2. Та ли это редакция
3. Нет ли исключения в другом фрагменте
4. О том ли вообще вопрос

помогает: reranker | фильтры по метаданным | порог и ответ «не нашёл» | проверка ответа

Несколько источников



Поиск — инструмент агента

КОНВЕЙЕР

Поиск перед каждым ответом



+ предсказуемо, один запрос
− ищем по словам пользователя

ИНСТРУМЕНТ

Модель решает, когда искать



+ сама пишет запросы и ищет повторно
− больше шагов и токенов

Как подать найденное модели

```
instructions:
  Отвечай только по фрагментам из входа.
  Если ответа в них нет, так и скажи.          1
  В конце укажи id фрагментов.                 2

input:
  <fragment id="policy-v3#4.2" version="3"     3
    valid="действует 2026-10-01 — сейчас">
  4.2. Изменение адреса доставки
  …Исключение: для заказов с экспресс-доставкой…
  </fragment>
  <fragment id="faq#1" …> … </fragment>        4

  Вопрос: Заказ уже оплачен.
  Можно поменять адрес доставки?
```

1. **Нет ответа — так и скажи**
2. **id фрагментов в ответе**
3. **Метаданные рядом с текстом**
4. **Только отобранное**

Ссылка ≠ доказательство

заказ A415 от 05.10.2026, экспресс

ОТВЕТ ПОМОЩНИКА

Для экспресс-заказов адрес можно менять до начала сборки

`sources: ["policy-v3#4.2"]`

Источник среди найденных
id есть в выдаче поиска
✓ да

Редакция действует на дату
ред. 3 — с 01.10, заказ от 05.10
✓ да

Утверждение есть во фрагменте
во фрагменте: «только до оплаты»
⚠ нет

</> Проверяет код: id из выдачи, цитата, даты

Проверяем по уровням

уровень 1

Поиск

Нужный фрагмент в первых k?

`recall@k`

уровень 2

Ответ

Верен, учтены исключения и редакция?

эталон или чек-лист

уровень 3

Опора

Каждое утверждение есть во фрагментах?

проверка ссылок

уровень 4

Задача

Агенту с поиском лучше, чем без?

решено · шаги · токены

набор вопросов: точные термины | перефразирование | исключения | редакции | ответа нет в базе

ДЕМО 3

Мини-кодер с поиском

github.com/Vasiliy566/hsm_lectures
wave_2/lesson_03/practice

ЗАПУСКАЕМ

```
python 04_mini_coder.py
```

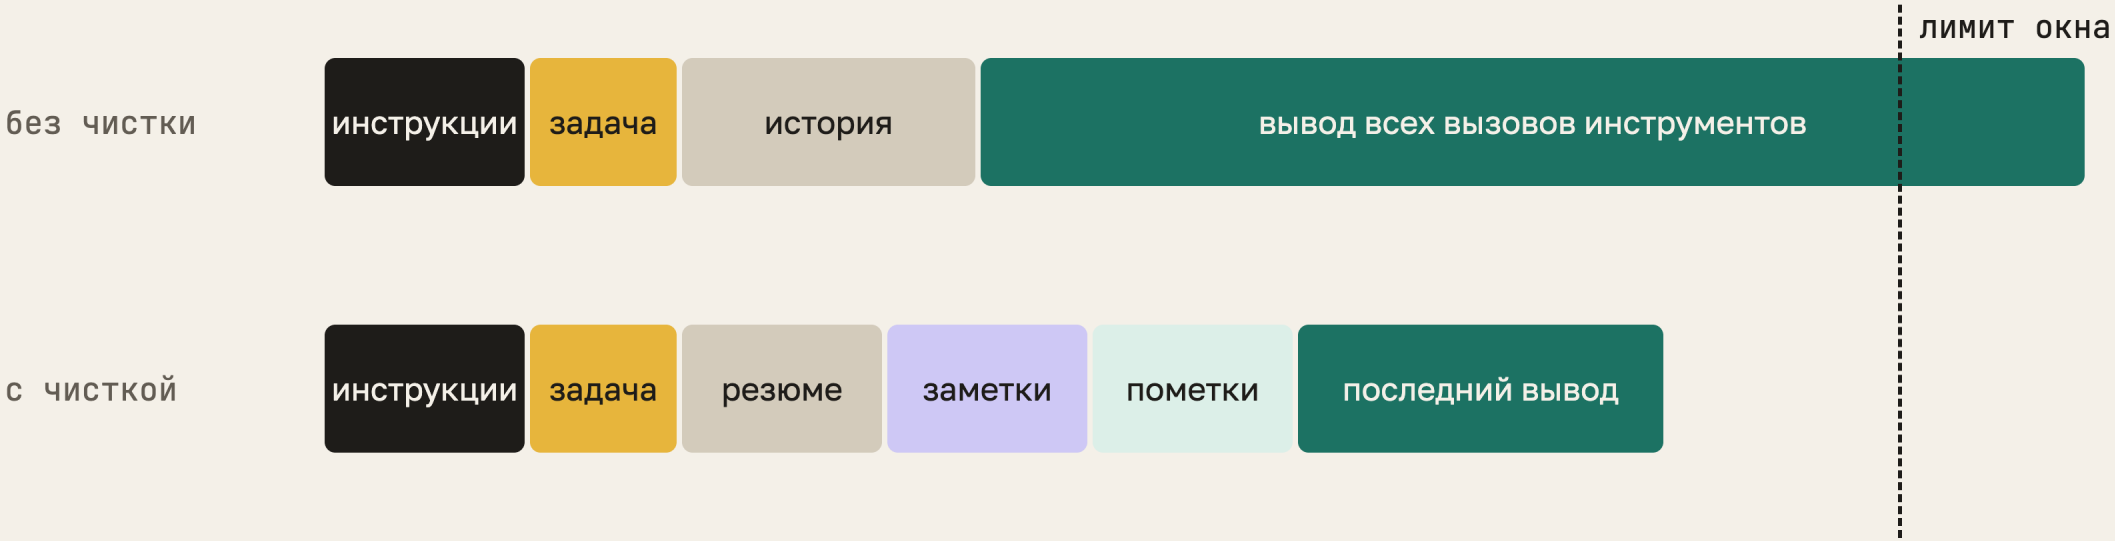
задача SEV-418

`search_docs` · `search_code` · `read_file` · `replace_in_file` · `run_tests`

СМОТРИМ

- Какие запросы агент пишет сам
- Сколько токенов во входе на каждом шаге
- Проверку программой в конце

Длинная задача: что убрать из входа



старый вывод → пометка

история → резюме

план и находки → заметки

Как выбрать способ

1

Всё во входе

мало текста

2

Инструменты чтения

код, точные имена

3

Поисковый индекс

много текста

4

Индекс + метаданные

редакции, права доступа

проще → сложнее

ДОМАШНЕЕ ЗАДАНИЕ 3 · PLANERVERSE.RU

Агент из ДЗ 2 держит вход коротким

есть

Агент из ДЗ 2

→

1

Лимит вывода

≤ 50 строк на вызов

→

2

Чистка истории

старый вывод → пометка

→

3

Сравнение с ДЗ 2

решено · шаги · токены

ВАРИАНТ Б поиск по своим документам: 10 вопросов с поиском и без

Термины занятия

Термин	Коротко
Контекст	Всё, что модель получает во входе на этом шаге
Контекст-инжиниринг	Выбор минимума сведений, достаточного для шага
RAG	Найти сведения во внешнем источнике и добавить во вход
Индексация	Подготовка заранее: разбор, нарезка, векторы, метаданные
Фрагмент, chunk	Часть документа — единица поиска
BM25	Поиск по словам: редкие совпадения весят больше
Эмбеддинг	Вектор текста; близкий смысл — близкие векторы
Reranker	Модель, которая заново оценивает кандидатов к вопросу
Метаданные	Источник, редакция, даты, права доступа
recall@k	Доля нужных фрагментов, попавших в первые k
Compaction	Сжатие истории, чтобы задача поместилась во вход

Что почитать

Контекст-инжиниринг	anthropic.com/engineering/effective-context-engineering-for-ai-agents
Contextual Retrieval	anthropic.com/news/contextual-retrieval
Домашки · AgentScore	planerverse.ru
Код занятия	github.com/Vasiliy566/hsm_lectures · wave_2/lesson_03

ЗАНЯТИЕ 1.4

Архитектуры агентов: план, проверка, несколько агентов